



# UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

---

FACULTAD DE CIENCIAS

## TAREA 6

Selección de modelos y regularización

Aguirre Armada Guillermo

Figuerola Torres Ivan Emiliano

Luna Gutiérrez Yanelly

Ortiz Silva Ana Beatriz

PROFESOR DE ASIGNATURA:  
Guillermina Eslava

PROFESOR DE ADJUNTO:  
Sofía Guzman

18 de enero de 2021

CIUDAD UNIVERSITARIA, CD. MX.



## Ejercicio 1.

Usamos la base `Boston` de la paquetería `MASS` para ajustar modelos de regresión. La base contiene 506 observaciones de 14 variables, 13 del tipo numéricas y una variable, `chas`, de tipo factor. Tomamos a la variable `crim` como nuestra variable predictora.

Realizamos una selección de modelos usando la paquetería `MASS` y `leaps`, para ajustar métodos: aditivo, step k=2, step k=log(506) y regsubset exhaustive; cómo se muestra en la siguiente tabla 1.

Utilizando Boxcox encontramos que con una  $\lambda = 0.02$ , la transformación óptima es la función  $\log()$ . Los modelos obtenidos fueron:

- Aditivo:  $= \log(\text{crim}) \sim$ .
- Step k=2:  $= \log(\text{crim}) \sim \text{zn} + \text{indus} + \text{nox} + \text{age} + \text{rad} + \text{ptratio} + \text{black} + \text{lstat} + \text{medv}$ .
- Step k=log(506)/regsubset:  $= \log(\text{crim}) \sim \text{zn} + \text{nox} + \text{age} + \text{rad} + \text{black} + \text{lstat}$ .

Al ajustar los modelos notamos que por el método step k=log(506) y por el regsubset exhaustive, llegabamos a la misma regresión con 6 variables explicativas.

	Aditivo	Step k=2	Step k=log(n)/Regsubsets
ECM Ap	0.58	0.58	0.596
ECM Val	0.623	0.599	0.607
p	13	9	6
R <sup>2</sup>	0.875	0.875	0.872
R <sup>2</sup> Adj	0.872	0.873	0.871
AIC	1191.48	1184.10	1190.06
BIC	1254.88	1230.59	1223.87

Table 1: **Estadísticas e información adicional de los modelos no regularizados.** *Vemos que las estadísticas de los modelos no difieren en gran tamaño unas de otras, a pesar de contar con diferentes números de variables*

Haciendo una selección de modelos y aplicando métodos regularizados obtenemos el ajuste de 6 modelos distintos, para medir su alcance predictivo calculamos su tasa de error aparente y de prueba.

Modelos	Error aparente	Error prueba
R. Aditiva	58.1	62.3
Step k=2	58.2	59.9
Step k=log(n)/Regsubsets	59.6	60.7
Lasso	58.5	61.9
Ridge	60.4	63.2
Elasticnet	58.2	61.7

Table 2: **Tasas error en porcentajes de modelos ajustados.** *Las primeras tres tasas pruebas fueron calculadas por training/ test con 300 repeticiones, las últimas tres con cv k=10.*

	TrnErr(Ap)	cv(k=10, B=1)	cvsd	betas(df)	lamda.min	lamda.lse
Lasso	0.587	0.608	0.033	10	0.021	0.124
Ridge	0.603	0.635	0.0347	14	0.184	0.425
Elasticnet	0.583	0.620	0.039	12	0.0183	0.206

Table 3: **Estadísticas e información adicional de modelos regularizados.** Vemos que las *cvsd* son similares para todos los modelos pero difieren en las *lamdas*, siendo la más pequeña mínima para *elasticnet* y la más pequeña *lse* para *Lasso*.

Modelos	Inter	zn	indus	chas1	nox	rm	age	dis	rad	tax	ptratio	black	lstat	medv
R. Aditiva	-3.73	-0.01	0.02	-0.04	3.84	-0.04	0.00	-0.00	0.14	0.00	-0.04	-0.00	0.03	0.01
Step k=2	-4.10	-0.01	0.02		3.86		0.00		0.14		-0.04	-0.00	0.03	0.00
Step k=log(n)	-4.83	-0.01			4.71		0.01		0.14			0.00	0.03	
Lasso		-0.01	0.02		3.94		0.01	-0.02	0.14		-0.02	0.00	0.02	
Ridge		-0.01	0.01	0.02	3.46	-0.02	0.01	-0.04	0.10	0.00	-0.02	0.00	0.03	0.01
Elasticnet		-0.01	0.02		3.86	-0.01	0.01	-0.02	0.14		-0.03	0.00	0.03	0.00

Table 4: **Valor de los coeficientes** asociados a los siete modelos seleccionados, recordemos que *Step k=log(n)* es el mismo modelo que *Regsubsets*.

Podemos observar que a pesar de ajustar distintos modelos, con diferentes números de variables, gracias a la transformación  $\log()$ , el poder predictivo de los modelos es similar en los 6 modelos, al igual que las estadísticas.

Si bien es con el modelo aditivo donde tenemos una tasa de error aparente menor (**58.1**), su tasa prueba es una de las más altas (**62.3**); caso contrario con el ajuste *Step k=2* (**59.9**) que se mantiene baja en comparación de los demás modelos y cambia sólo un **0.7** por cierto.

Nosotros consideramos que el modelo que seleccionaríamos con respecto a su poder predictivo, ya que contempla a 9 de las 13 variables predictoras, tiene unas  $R^2$ s que están por encima de las otras, aunque no sea muy significativo el cambio (0.001), es la que tiene menor AIC y la segunda que tiene menor BIC, incluyendo lo antes mencionado con respecto a las tasas de error.

## Ejercicio 2.

En este ejercicio usamos la información de la base *riboflavin* del paquete *hdi*, la cual contiene 73 observaciones de 4088 variables predictoras (*x*) y una variable respuesta (*y*). Todas las variables son numéricas.

Ajustamos tres modelos regularizados usando la función *glmnet()* del paquete *glmnet*.

- *ridge* ( $\alpha = 0$ )
- *lasso* ( $\alpha = 1$ )
- *elastic net* ( $\alpha = 0.5$ )

Para elegir el valor de  $\lambda$  óptimo utilizamos la función *cv.glmnet()* con  $k=10$ , la cual usa validación cruzada sobre 100 modelos con distintos valores de  $\lambda$ . Encontramos que el valor de  $\lambda$  que minimiza el error cuadrático medio para cada modelo, el cual se encuentra en la Tabla , así como el numero de coeficientes distintos de cero para dicho valor de  $\lambda$ . En la Tabla se muestran los valores del error cuadrático medio aparente y validadas para cada modelo. Podemos observar que el ECM incrementa en promedio solo 0.20 en cada modelo y se mantiene bastante estable entre una y 100 repeticiones.

	<i>ridge</i>	<i>lasso</i>	<i>elastic net</i>
ECM aparente	0.028	0.042	0.037
ECM cv(k=10, B=1)	0.262	0.200	0.216
ECM cv(k=10, B=100)	0.262	0.210	0.220
$\lambda_{minECM}$	5.934	0.042	0.069

Table 5: **Tasas de error de los modelos regularizados y su correspondiente valor de  $\lambda_{min}$ .** Usamos 10 *folds* en validación cruzada, con una repetición y con 100 repeticiones.

Para los modelos que seleccionamos usando el criterio de  $\lambda_{min}$  calculamos el número de coeficientes que en valor absoluto son mayores 0.025:

<i>ridge:</i> 6		<i>lasso:</i> 29		<i>elastic net:</i> 42	
xLYSC_at	-0.033	xYOAB_at	-0.784	xYOAB_at	-0.563
xYEBC_at	-0.032	xYEBC_at	-0.531	xYEBC_at	-0.497
xYFIT_at	0.032	xLYSC_at	-0.270	xLYSC_at	-0.396
xSPOVAA_at	0.028	xSPOVAA_at	0.247	xSPOVAA_at	0.283
xYBFI_at	0.027	xYQJU_at	0.213	xYQJU_at	0.198
xHUTP_at	-0.027	xYXLD_at	0.197	xYBFI_at	0.173

Table 6: **Coefficientes con mayor valor absoluto** para cada uno de los modelos y su variable asociada.

	<i>ridge</i>	<i>lasso</i>	<i>elastic net</i>
$\lambda_{minECM}$	5.93	0.042	0.069
Num. betas ( $\lambda_{minECM}$ )	4089	38	57
$\lambda_{1se}$	30.22	0.080	0.161
Num. betas ( $\lambda_{1se}$ )	4089	29	42
$\lambda_{maxdf}$	-	0.006	0.012
Num. betas ( $\lambda_{maxdf}$ )	-	72	90

Table 7: **Información adicional de los modelos.** Valores de  $\lambda$  que cumplen tres criterios ( $\lambda_{min}$ ,  $\lambda_{1se}$ ,  $\lambda_{maxdf}$ ) y su correspondiente número de coeficientes que son distintos de cero.

## Anexo

### Ejercicio 1

```
Call: Modelo aditivo
lm(formula = log(crim) ~ ., data = Boston)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-2.570 -0.555 -0.037  0.502  2.627
```

Coefficients:

```
      Estimate Std. Error t value Pr(>|t|)
(Intercept) -3.732873    0.868764  -4.30  2.1e-05 ***
zn          -0.011685    0.002250  -5.19  3.0e-07 ***
indus        0.019756    0.010016   1.97  0.04911 *
```

chas1	-0.048092	0.141711	-0.34	0.73448
nox	3.846813	0.633484	6.07	2.5e-09 ***
rm	-0.048985	0.073588	-0.67	0.50594
age	0.005988	0.002152	2.78	0.00561 **
dis	-0.005438	0.033840	-0.16	0.87241
rad	0.142856	0.010573	13.51	< 2e-16 ***
tax	-0.000132	0.000619	-0.21	0.83110
ptratio	-0.041137	0.022389	-1.84	0.06675 .
black	-0.001502	0.000441	-3.40	0.00072 ***
lstat	0.031705	0.009093	3.49	0.00053 ***
medv	0.010469	0.007267	1.44	0.15030

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.773 on 492 degrees of freedom

Multiple R-squared: 0.875, Adjusted R-squared: 0.872

F-statistic: 266 on 13 and 492 DF, p-value: <2e-16

Call: Step k=2

```
lm(formula = log(crim) ~ zn + indus + nox + age + rad + ptratio +
    black + lstat + medv, data = Boston)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.5680	-0.5614	-0.0362	0.5004	2.6822

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	-4.100828	0.642667	-6.38	4.0e-10 ***
zn	-0.012056	0.001963	-6.14	1.7e-09 ***
indus	0.019619	0.008676	2.26	0.02417 *
nox	3.866694	0.596785	6.48	2.2e-10 ***
age	0.005775	0.002016	2.86	0.00435 **
rad	0.140597	0.006007	23.41	< 2e-16 ***
ptratio	-0.040579	0.022274	-1.82	0.06908 .
black	-0.001463	0.000433	-3.38	0.00079 ***
lstat	0.033694	0.008596	3.92	0.00010 ***
medv	0.008872	0.006169	1.44	0.15099

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.771 on 496 degrees of freedom

Multiple R-squared: 0.875, Adjusted R-squared: 0.873

F-statistic: 387 on 9 and 496 DF, p-value: <2e-16

Call: Step k=log(n) o Regsubsets

```
lm(formula = log(crim) ~ zn + nox + age + rad + black + lstat,
    data = Boston)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-2.6807	-0.5935	-0.0218	0.4972	2.6319

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	-4.833234	0.302201	-15.99	< 2e-16 ***
zn	-0.011106	0.001839	-6.04	3e-09 ***
nox	4.714298	0.507822	9.28	< 2e-16 ***
age	0.006579	0.001989	3.31	0.00101 **
rad	0.137756	0.005312	25.93	< 2e-16 ***
black	-0.001456	0.000433	-3.36	0.00084 ***
lstat	0.025020	0.006542	3.82	0.00015 ***

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.777 on 499 degrees of freedom

Multiple R-squared: 0.872, Adjusted R-squared: 0.871

F-statistic: 568 on 6 and 499 DF, p-value: <2e-16

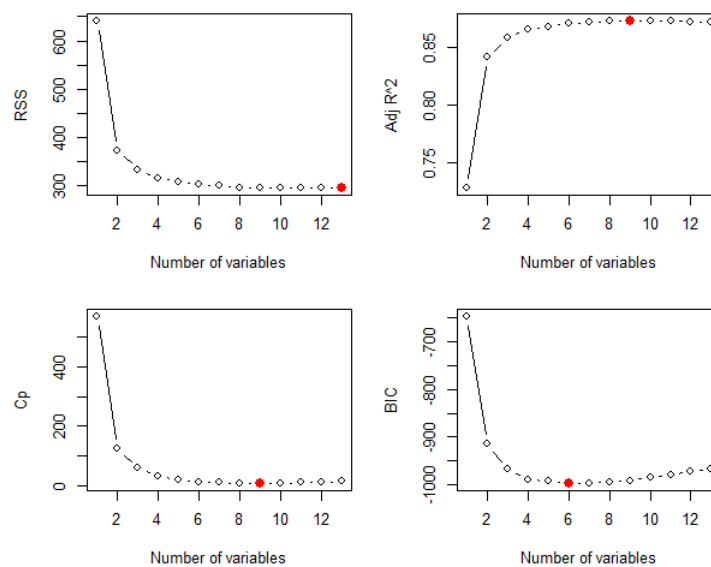


Figure 1: **Modelo *Regsubset*, method *Exhaustive*.**




Figure 2: Modelo *lasso*.

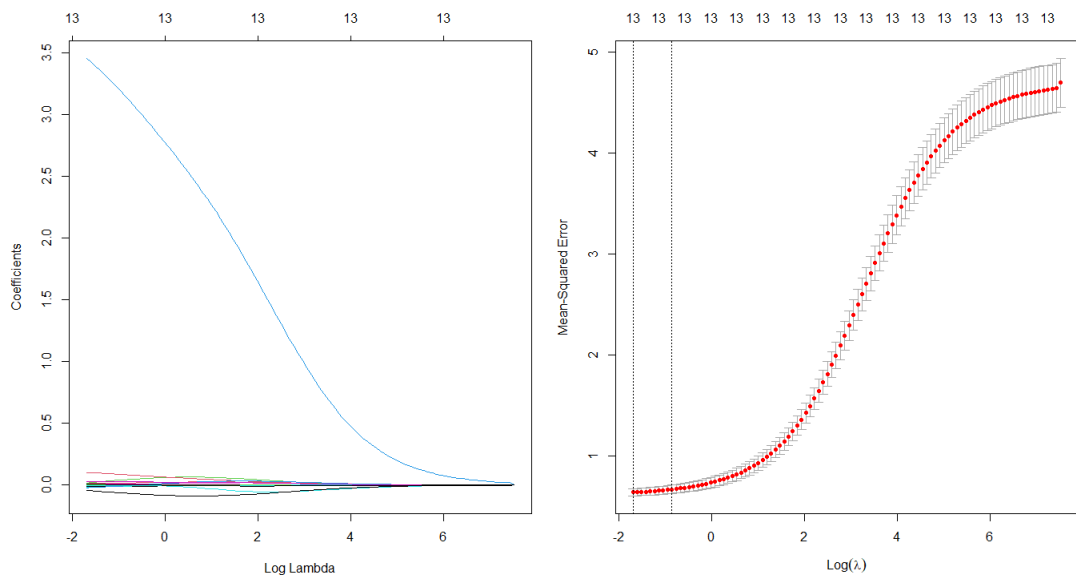


Figure 3: Modelo *ridge*.




Figure 4: **Modelo *elastic net* con  $\alpha = 0.5$**

Ejercicio 2 Para los modelos que seleccionamos usando el criterio de  $\lambda_{min}$  calculamos el número de coeficientes que en valor absoluto son mayores 0.025:

<i>ridge</i> : 6		<i>lasso</i> : 29		<i>elastic net</i> : 42	
xLYSC_at	-0.033	xYOAB_at	-0.784	xYOAB_at	-0.563
xYEBC_at	-0.032	xYEBC_at	-0.531	xYEBC_at	-0.497
xYFIT_at	0.032	xLYSC_at	-0.270	xLYSC_at	-0.396
xSPOVAA_at	0.028	xSPOVAA_at	0.247	xSPOVAA_at	0.283
xYBFI_at	0.027	xYQJU_at	0.213	xYQJU_at	0.198
xHUTP_at	-0.027	xYXLD_at	0.197	xYBFI_at	0.173

Table 8: **Coefficientes con mayor valor absoluto** para cada uno de los modelos y su variable asociada.

	<i>ridge</i>	<i>lasso</i>	<i>elastic net</i>
$\lambda_{minECM}$	5.93	0.042	0.069
Num. betas ( $\lambda_{minECM}$ )	4089	38	57
$\lambda_{1se}$	30.22	0.080	0.161
Num. betas ( $\lambda_{1se}$ )	4089	29	42
$\lambda_{maxdf}$	-	0.006	0.012
Num. betas ( $\lambda_{maxdf}$ )	-	72	90

Table 9: **Información adicional de los modelos.** Valores de  $\lambda$  que cumplen tres criterios ( $\lambda_{min}$ ,  $\lambda_{1se}$ ,  $\lambda_{maxdf}$ ) y su correspondiente número de coeficientes que son distintos de cero.

Para los 3 modelos es posible notar que el valor de  $\lambda$  que minimiza el error cuadrático medio no restringe demasiado a las  $\beta$  siendo en el primero en el que tienen más libertad.






Figure 5: **Modelo *ridge*.**




Figure 6: **Modelo *lasso*.**




Figure 7: *Modelo elastic net con alpha = 0.5*